# THAI LEGAL RAG Q&A SYSTEM

Domain: Legal documents






อองรักษ์ วณิชชานัย
67070297



ณภัทร วานิชวัตถากร
67070226



พลาธิป เหมวุฒิ
67070255



เอื้ออังกูร ชัยวิวัฒน์พร
67070302

# PROBLEM



## 1. Domain Challenges

- โครงสร้างเป็นลำดับชั้นเคร่งครัด (หมวด → ส่วน → มาตรา → วรรค → อนุมาตรา)
- คำศัพท์เฉพาะทางสูง (Technical Legal Jargon) เช่น "คริปโทเคอร์เรนซี", "ตั๋วเงินคลัง", "ผู้มีส่วนได้เสีย"
- กฎเกณฑ์มีเงื่อนไขและข้อยกเว้น หากดึงข้อความไม่ครบถ้วน คำตอบทางกฎหมายจะผิดเพี้ยนทันที

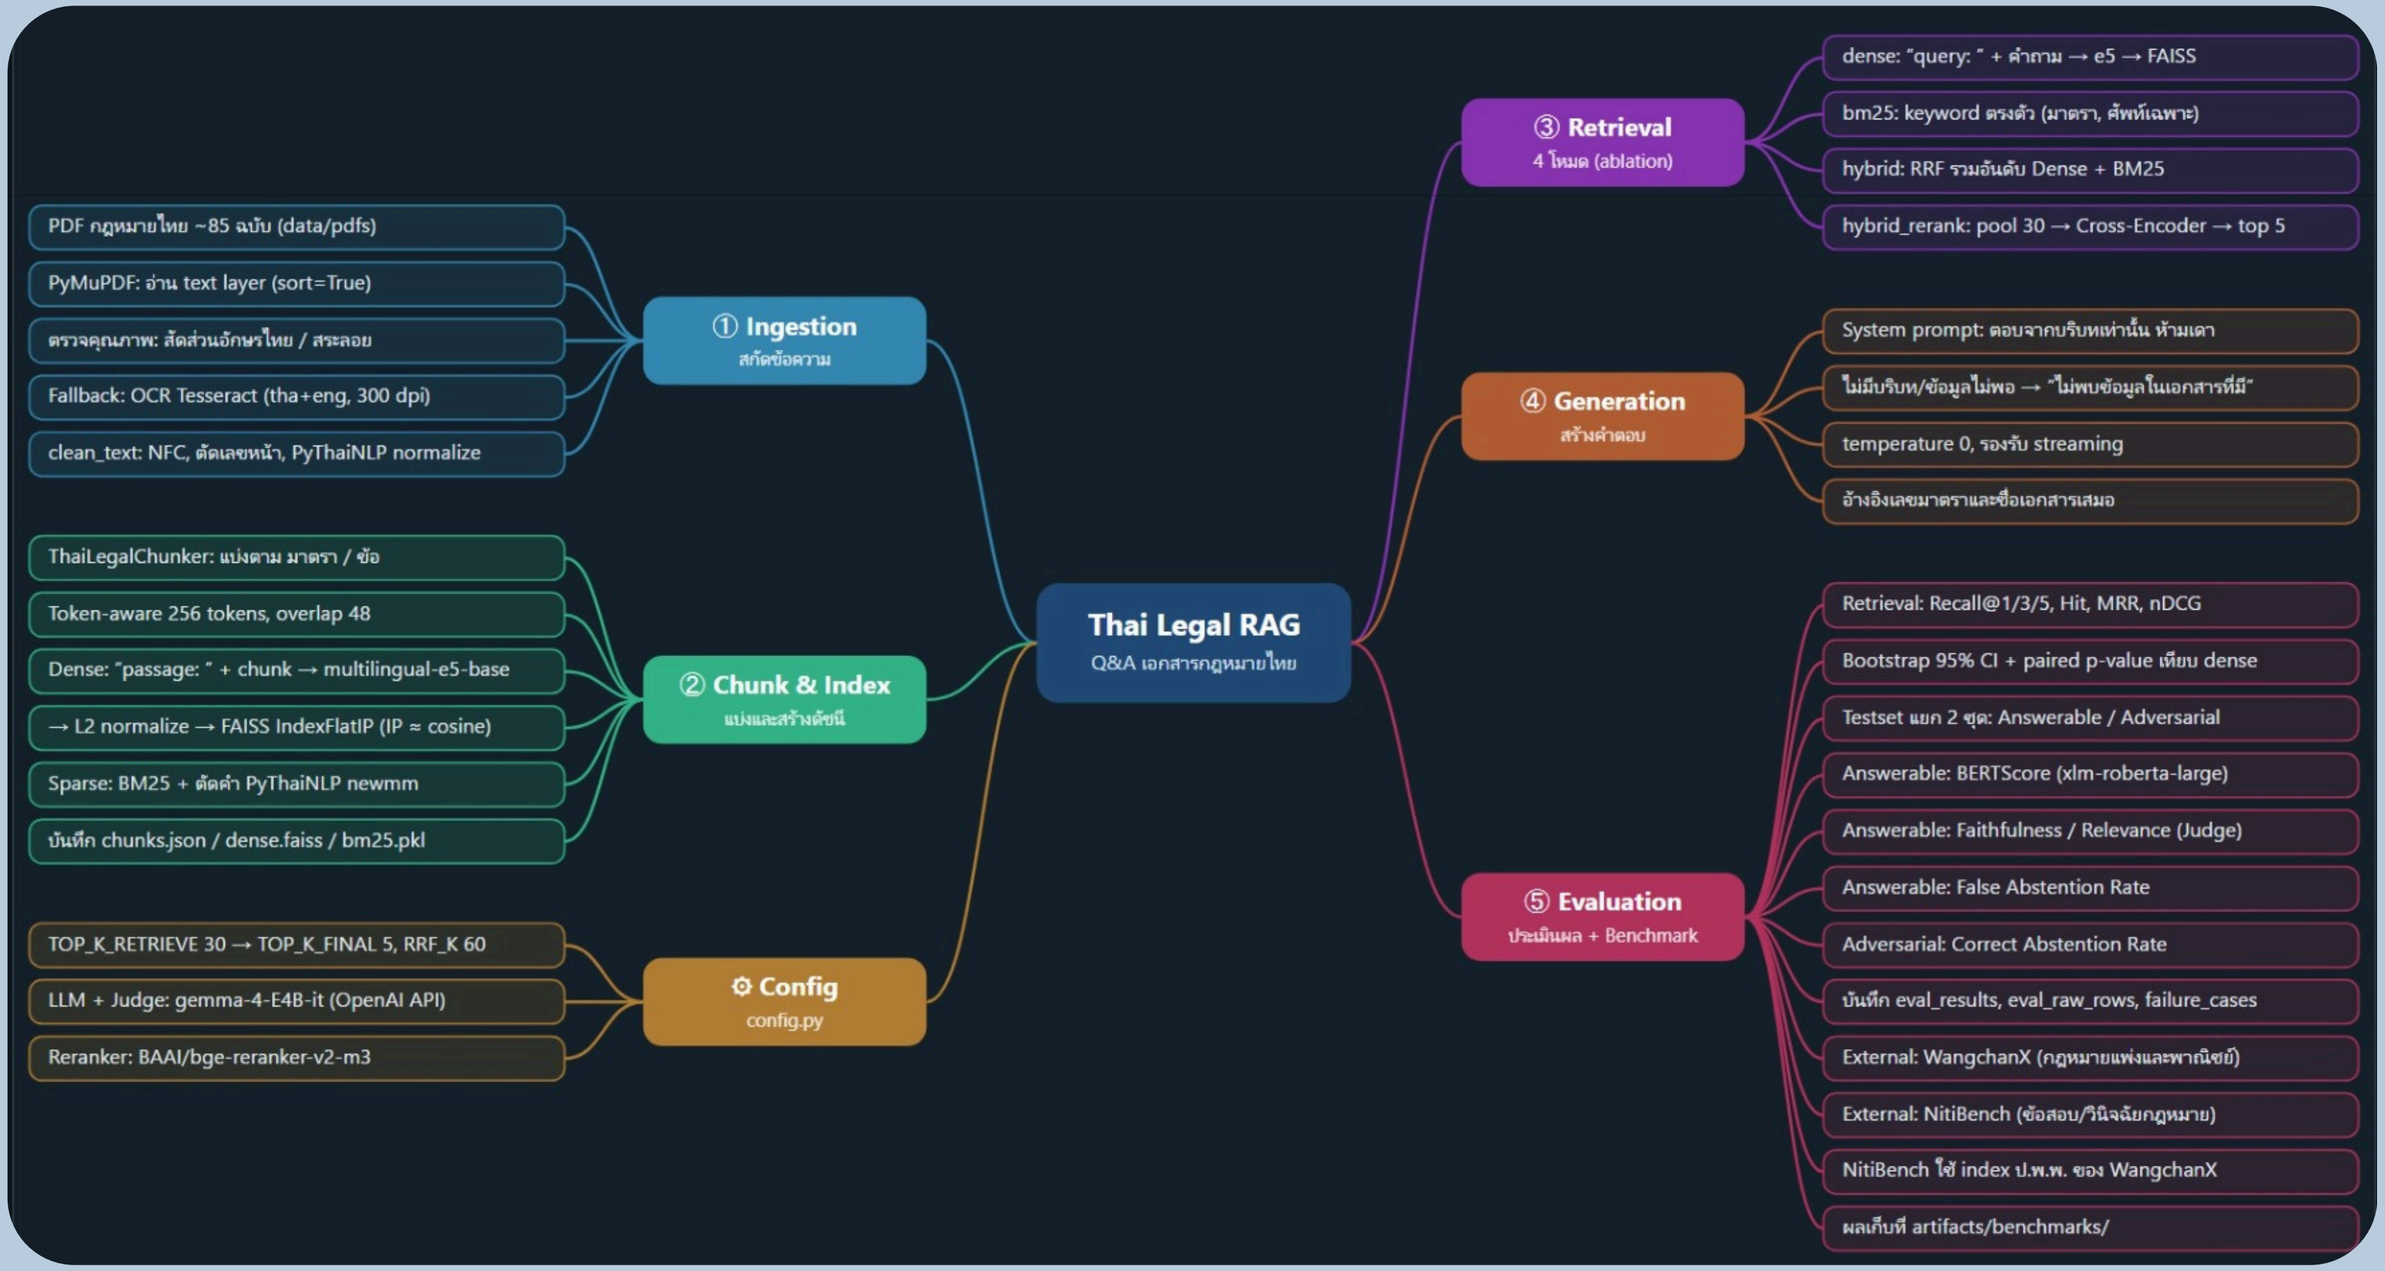
## 2. ข้อจำกัดของ LLMs ทั่วไป

- เกิด Hallucination สร้างเลขมาตราและบทลงโทษที่ไม่มีอยู่จริง
- ขาด Grounding อัปเดตไม่ทันพระราชบัญญัติใหม่ๆ

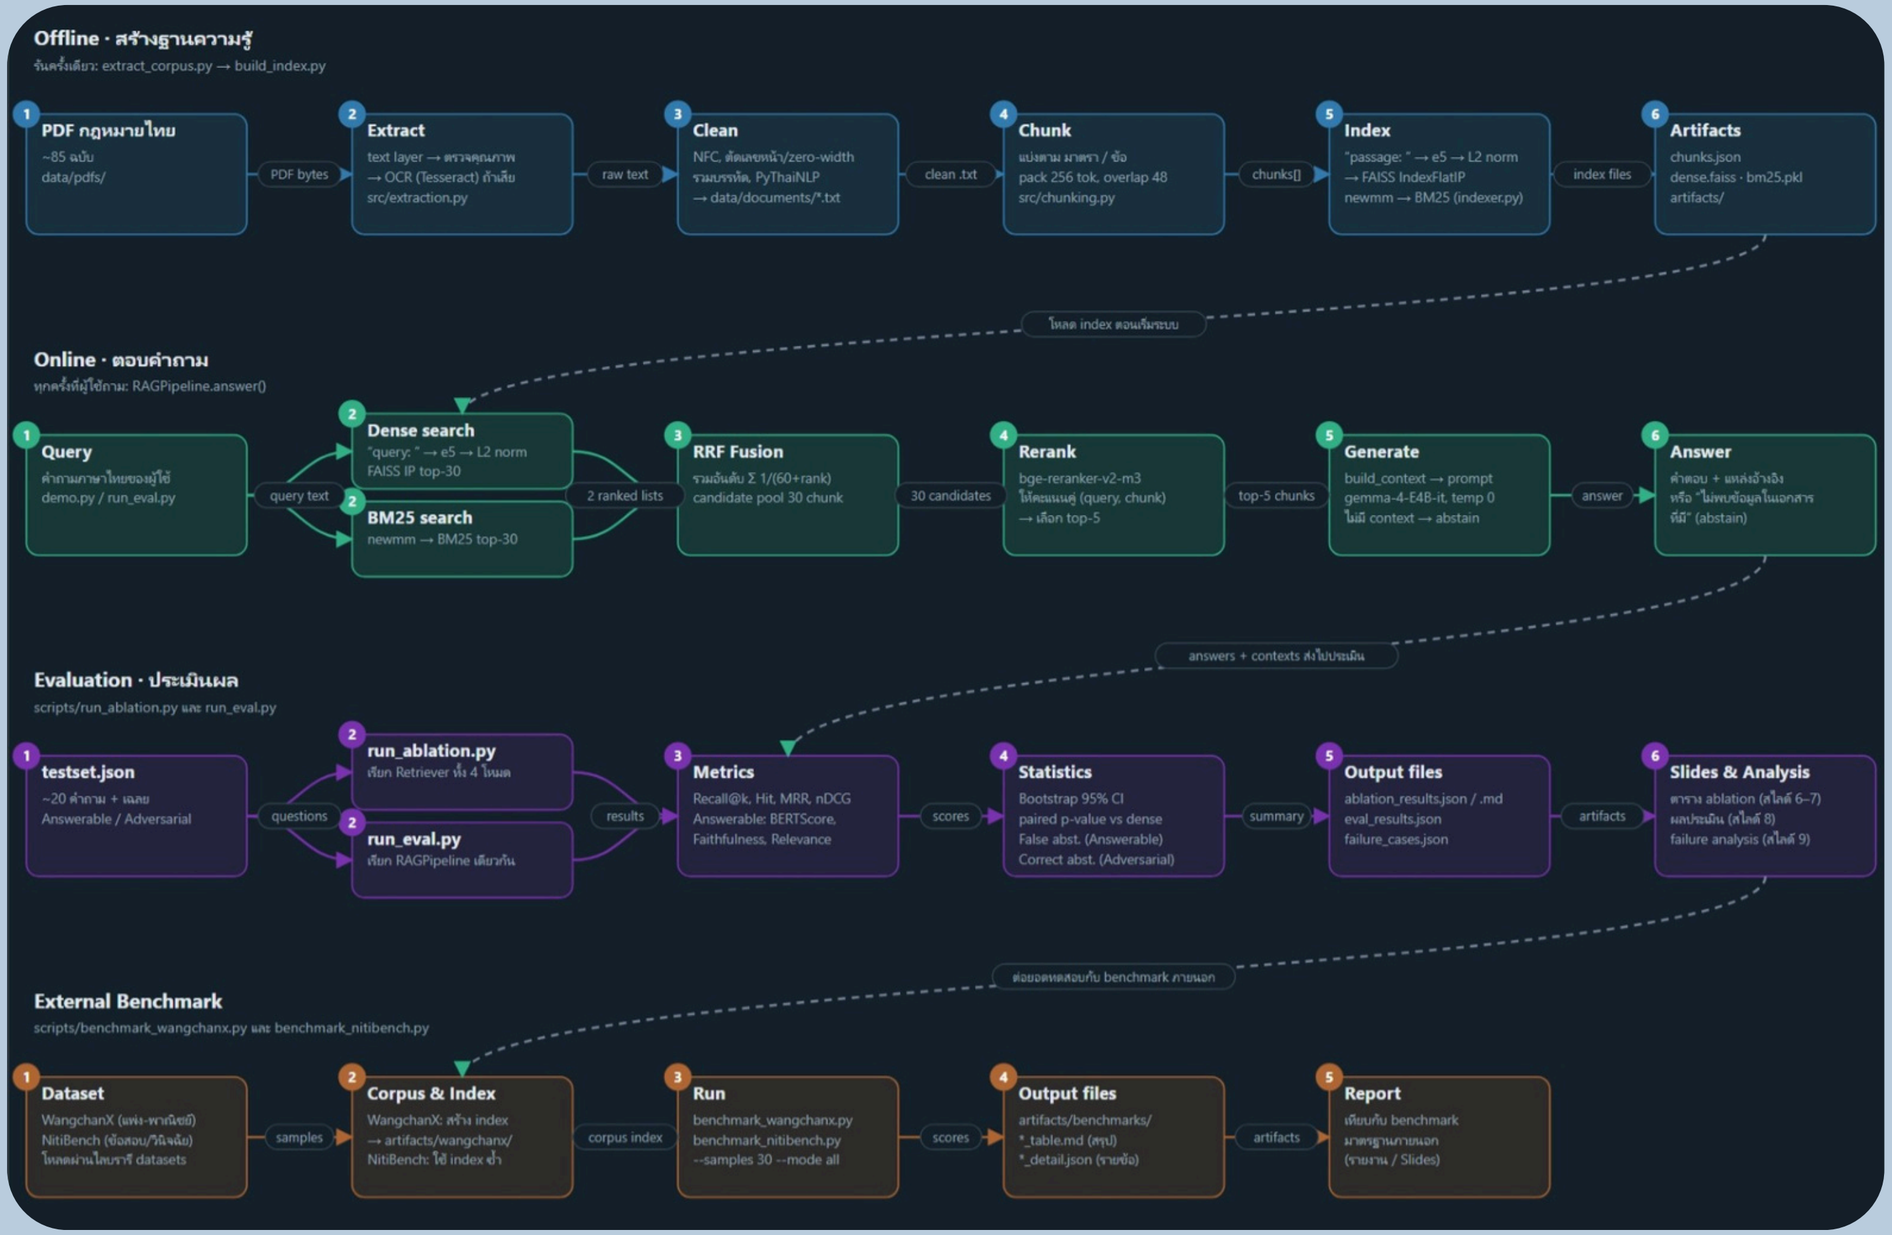
## 3. ความท้าทายของ RAG ทั่วไป เมื่อเจอบริบทภาษากฎหมาย

- การตัดข้อความแบบ Character/Fixed-word จะตัดผ่ากลางมาตรา ทำลายเงื่อนไขและข้อยกเว้น
- Dense Search เพียงอย่างเดียวพลาดคำเฉพาะทางกฎหมาย (Low Exact-Keyword Recall)
- ไฟล์ PDF กฎหมายไทยมักพบปัญหา "สระลอย" และรหัสฟอนต์เพี้ยน ทำให้ Vector ผิดเพี้ยน

# SYSTEM ARCHITECTURE DIAGRAM

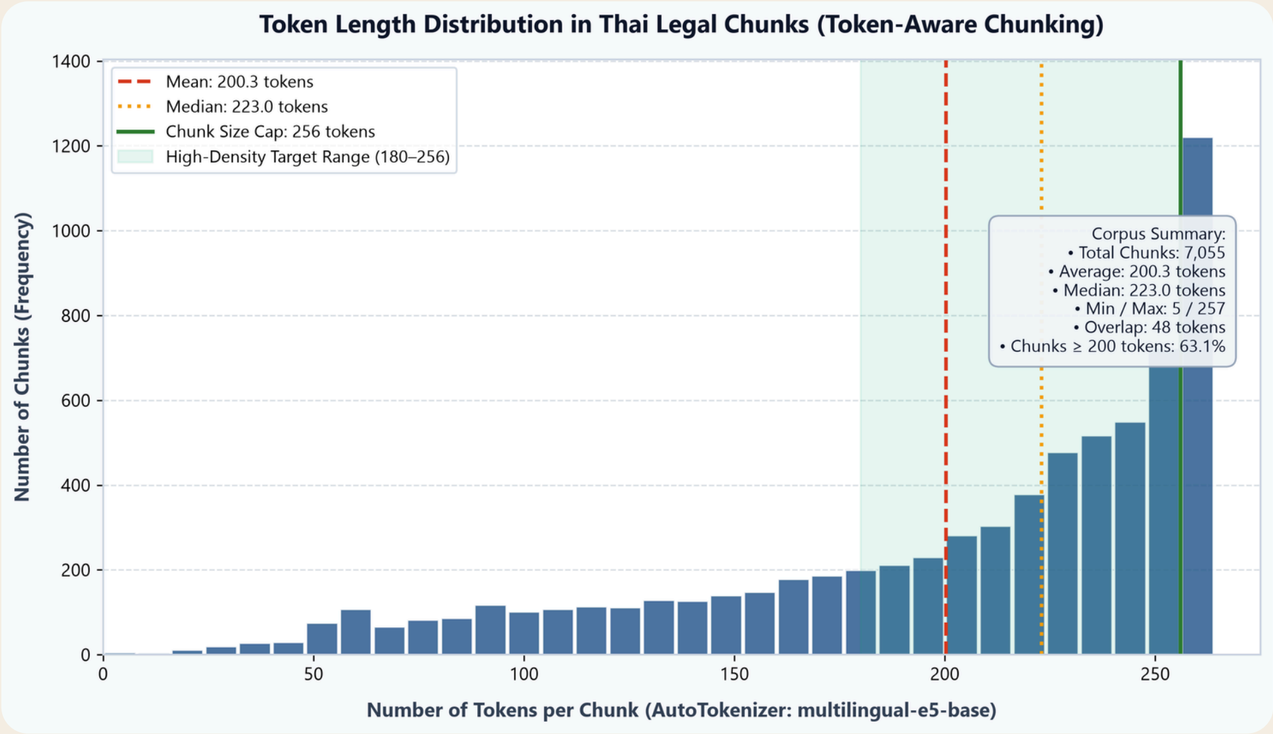


# PIPELINE FLOW



# KEY TECHNICAL SOLUTION

INGESTION & CHUNKING STRATEGY




📦 **Short Sections Packing Example (ป.พ.พ. บรรพ ๒ หนึ่ง):**

**มาตรา ๑๙๕ + มาตรา ๑๙๖ + มาตรา ๑๙๗**

**→ รวมเหลือ 1 Chunk = 219 Tokens (พอดีกับเป้าหมาย 256 tokens)**

## 1. Ingestion & OCR Guard (ความสมบูรณ์ 100%)

- สกัด Text Layer สำเร็จ 83/85 ฉบับ
- Auto-Fallback สู่ Tesseract OCR (ภาษาไทย) 2 ฉบับ เมื่อพบสระลอย/อักขระเสีย

## 2. Structure & Token-Aware Chunking

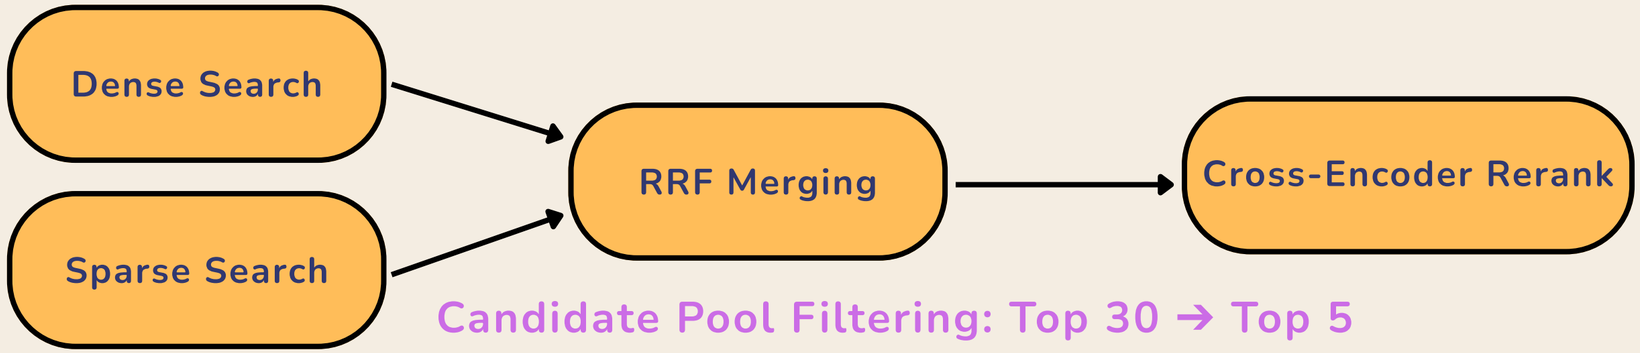
- Regex Splitting: ดักจับหัวข้อ มาตรา (พ.ร.บ.) และ ข้อ (ระเบียบราชการ) ป้องกันการตัดผ่ากลาง
- AutoTokenizer (E5): นับความยาวตาม Token จริง (ไม่ใช่จำนวนตัวอักษร)
- Section Packing: แพ็กรวมมาตราสั้นเข้าด้วยกัน (คิดเป็น 53.1% ของคลังข้อมูล) ลดขยะเวกเตอร์

## 3. เหตุผลที่ล็อก Chunk Size = 256 Tokens

- ❌ 512+ tokens: กว้างเกินไป รวมหลายมาตรา เกิด Semantic Dilution (ความหมายเวกเตอร์เจือจาง)
- ❌ 128 tokens: สั้นเกินไป ตัดวรรคเงื่อนไข/บทลงโทษหลุด เกิด Context Fragmentation (บริบทขาดตอน)
- 256 tokens: จุดสมดุลสูงสุด และปลอดภัยต่อ Input Limit (512 tokens) ของโมเดล E5

# KEY TECHNICAL SOLUTION

MULTI-STAGE HYBRID RETRIEVAL




**1. Dense Retrieval (Semantic Search)**

- Model: intfloat/multilingual-e5-base (768-dim, CPU Inference)
- Asymmetric Prefixes: passage: (Indexing) และ query: (Search)
- Normalization: L2-Normalized เวกเตอร์ เพื่อให้ FAISS IndexFlatIP ทำงานแบบ Cosine Similarity

**2. Sparse Retrieval (Lexical Exact Match)**

- Model: BM25Okapi + PyThaiNLP newmm Tokenizer
- Purpose: กู้คืนคำศัพท์เฉพาะทางกฎหมาย เช่น "สินทรัพย์ดิจิทัล", "ตั๋วเงินคลัง" และเลขมาตราที่ Dense มองข้าม

**3. Score-Agnostic Fusion (RRF)**

- ผสานผลลัพธ์ด้วย Reciprocal Rank Fusion (RRF, k=60)
- จุดเด่น: รวมอันดับ 1 / (60 + rank) โดยไม่ต้องทำ Score Normalization ระหว่าง Cosine (0–1) กับ BM25

**4. Stage-2 Reranking (Cross-Attention Precision)**

- Model: BAAI/bge-reranker-v2-m3 (Cross-Encoder)
- ทำ Full Token Cross-Attention วิเคราะห์ความสัมพันธ์เชิงลึกของคู่ (Query, Passage)
- Candidate Strategy: ดึง Candidate Pool Top 30 ➔ คัดกรองเหลือหัวกะทิ Top 5 ส่งเข้า LLM

# ABLATION RESULTS

## Thai Legal RAG — Ablation: เทียบ 4 โหมด Retrieval

แต่ละโหมดค่อย ๆ เพิ่มขั้นตอนเข้าไป: Dense → BM25 → Hybrid (RRF) → Hybrid + Rerank

| โหมด | Recall@1 | Recall@3 | Recall@5 | MRR | Latency / คำถาม |
|---|---|---|---|---|---|
| **Dense**<br>e5 + FAISS อย่างเดียว<br>`dense` | 0.9000 | 1.0000 | 1.0000 | 0.9500 | **86.6 ms**<br>ฐานเทียบ |
| **BM25**<br>คำตรงตัว (newmm)<br>`bm25` | 0.9500 | 0.9500 | 1.0000 | 0.9625 | **98.8 ms**<br>1.1× ของ dense |
| **Hybrid**<br>Dense + BM25 รวมด้วย RRF<br>`hybrid` | 0.9500 | 1.0000 | 1.0000 | 0.9750 | **145.5 ms**<br>1.7× ของ dense |
| **Hybrid + Rerank**<br>Hybrid → Cross-Encoder เลือก top-5<br>`hybrid_rerank` | 1.0000 | 1.0000 | 1.0000 | 1.0000 | **24.85 s**<br>286.9× ของ dense |



# BENCHMARK



| Variant | Hit@1 | Hit@3 | Hit@5 | MRR | Latency |
|---|---|---|---|---|---|
| Dense | 0.4000 | 0.4333 | 0.4667 | 0.4233 | 30.91 ms |
| BM25 | 0.4333 | 0.4667 | 0.4667 | 0.4500 | 30.73 ms |
| Hybrid | 0.4333 | 0.4667 | 0.4667 | 0.4500 | 45.00 ms |
| Hybrid + Reranker | 0.4667 | 0.4667 | 0.4667 | 0.4667 | 16,088 ms |
| Variant | Hit@1 | Hit@3 | Hit@5 | MRR | Latency |

NITIBENCH

| Variant | Hit@1 | Hit@3 | Hit@5 | MRR | Latency |
|---|---|---|---|---|---|
| Dense | 0.6333 | 0.8000 | 0.8000 | 0.7000 | 31.69 ms |
| BM25 | 0.5667 | 0.7667 | 0.8000 | 0.6511 | 17.84 ms |
| Hybrid | 0.6000 | 0.8000 | 0.8333 | 0.7028 | 51.41 ms |
| Hybrid + Reranker | 0.7667 | 0.8333 | 0.8667 | 0.8011 | 20,234.32 ms |
| Variant | Hit@1 | Hit@3 | Hit@5 | MRR | Latency |

WANGCHANX

**Hit@k กับ Recall@k ต่างกันอย่างไร**

- Hit@k เหมาะสำหรับดูว่าระบบดึงเอกสารที่เกี่ยวข้องมาให้ LLM อย่างน้อยหนึ่งฉบับหรือไม่ (Top-k มีเอกสารที่เกี่ยวข้องอย่างน้อยหนึ่งฉบับไหม?)
- Recall@k เหมาะสำหรับดูว่าระบบดึงเอกสารที่เกี่ยวข้องได้ครบเพียงใด ซึ่งสำคัญเมื่อคำตอบขึ้นอยู่กับหลายมาตรา หลายวรรค หรือข้อยกเว้น (ค้นพบเอกสารที่เกี่ยวข้องทั้งหมดได้กี่สัดส่วน?)



# EVALUATION RESULTS

| Metric | ผลลัพธ์ | ความหมาย |
|---|---|---|
| Faithfulness | 5 / 5 | ตอบตรงกับเอกสาร - 20/20 ข้อได้เต็ม |
| Relevance | 5 / 5 | ตอบตรงคำถาม - 20/20 ข้อได้เต็ม |
| BERTScore F1 | 0.912 | ความคล้ายเชิงความหมาย<br>(Precision 0.876, Recall 0.951) |
| False Abstention | 0 / 20 | ไม่มีกรณีที่ตอบได้แต่ระบบปฏิเสธตอบ |
| Correct Abstention | 5 / 5 | คำถามที่ไม่มีคำตอบในเอกสาร ระบบปฏิเสธถูกครบทุกข้อ |



# FAILURE ANALYSIS

| ความล้มเหลว | สาเหตุ |
| --- | --- |
| Hallucination Risk | ระบบตอบคำถาม adversarial ที่ควรจะ abstain |
| Over-Refusal Risk | ระบบ abstain ทั้งที่ retriever เจอเอกสารที่เกี่ยวข้องแล้ว |
| Chunking Coverage Gap | Chunker ตรวจจับโครงสร้างเอกสารด้วยคำว่า "มาตรา" ทำให้เอกสารประเภท "ระเบียบ/ข้อบังคับ" ที่ใช้คำว่า "ข้อ" แทน ไม่ถูกแบ่ง chunk ตามโครงสร้างที่ถูกต้อง |

# AI AUDIT HIGHLIGHTS

| AI Audit ที่สำคัญ | Prompt ที่ใช้ | ผลลัพธ์จาก AI (ย่อ) | การตรวจสอบและแก้ไข (Human Verification) |
|---|---|---|---|
| แยก Eval Answerable / Adversarial | ตรวจสอบ Evaluation Pipeline เพราะ testset มีทั้งคำถามที่มีคำตอบอยู่ใน corpus และคำถาม adversarial ที่ตั้งใจถามสิ่งที่ไม่มีใน corpus ถ้านำทุกข้อมาเฉลี่ย BERTScore และ Faithfulness รวมกันจะเกิดปัญหาหรือไม่ | เสนอให้แยกกลุ่ม Answerable (BERTScore, Faithfulness, Relevance) กับ Adversarial (Correct Abstention Rate) ป้องกันคะแนนบิดเบือน | ปรับ run_eval.py และ logic ใน src/evaluation.py ให้แยก Answerable และ Adversarial ออกจากกันอย่างชัดเจน |
| ปรับ Ablation วัด Retrieval ล้วน | ช่วยตรวจสอบและปรับปรุง run_ablation.py สำหรับเปรียบเทียบ Dense, BM25, Hybrid และ Hybrid + Reranker โดยต้องการวัดเฉพาะประสิทธิภาพของ Retrieval ไม่ให้ผลของ LLM Generator เข้ามาปะปน | เสนอ 4 Variants (dense/ bm25/ hybrid/ hybrid_rerank) วัดด้วย Recall@k, Hit@k, nDCG, MRR, Latency + Bootstrap CI | ปรับ run_ablation.py ให้ใช้เฉพาะคำถาม Answerable ที่มี Gold Document และเรียก Retrieval โดยตรงแทนการเรียก Full Generation Pipeline<br>เพิ่มการ normalize Document ID ผ่าน src/metrics.py และรองรับ Ground Truth หลายรูปแบบ เช่น relevant_docs, gold_docs, source_doc และ doc_id<br>เพิ่มการรายงาน Bootstrap 95% CI, latency และข้อมูล diagnostics ของ reranker เพื่อให้สามารถวิเคราะห์ผล Retrieval ได้โดยไม่ปะปนกับคุณภาพของ LLM Generator |
| ตรวจ Methodology (Judge = Generator) | ตรวจสอบว่าการใช้ LLM ตัวเดียวกันเป็นทั้ง Generator และ LLM-as-Judge มีปัญหาทาง Methodology หรือไม่ เพราะโปรเจกต์ใช้โมเดลเดียวกันเนื่องจากข้อจำกัดด้านค่าใช้จ่าย | เตือนความเสี่ยงด้าน Methodology เพราะ Judge ไม่เป็นอิสระจาก Generator แนะนำใช้โมเดลแยกกันถ้ามีทรัพยากร | ไม่ได้เปลี่ยนโมเดลเนื่องจากข้อจำกัดด้านทรัพยากรและค่าใช้จ่ายของโปรเจกต์<br>ทีมเลือกเก็บ LLM-as-Judge ไว้ตาม implementation เดิม และบันทึกข้อจำกัดดังกล่าวเป็น **Evaluation Limitation** ของระบบ เพื่อให้ผลการประเมินมีความโปร่งใสและไม่ตีความว่าเป็นการประเมินจากผู้ประเมินที่เป็นอิสระอย่างสมบูรณ์ |

| Error Catch ที่สำคัญ | What the AI said | Why it was wrong | How you fixed it |
|---|---|---|---|
| AI ด่วนสรุปว่า Text Extraction ล้มเหลว ทั้งที่จริงเป็นปัญหา Regex | เมื่อสคริปต์สกัดข้อความ extract_corpus.py แจ้งเตือนว่า "⚠️ ไม่เจอคำว่า 'มาตรา' 2 ไฟล์" และแสดง Warning รายการไฟล์สภาฯ ขึ้นมา AI แนะนำให้ปรับ Regex หรืออาจต้องสั่งรัน OCR ใหม่เพราะคาดว่าดึงข้อความไม่สำเร็จ | AI ด่วนสรุปว่าการไม่พบคำว่า "มาตรา" คือความล้มเหลวของการทำ Text Extraction แต่ในความเป็นจริงของบริบทกฎหมายไทย ทั้ง 2 ไฟล์ดังกล่าวคือ "ระเบียบสภาผู้แทนราษฎร" ซึ่งรูปแบบทางกฎหมายใช้คำว่า "ข้อ" (เช่น ข้อ 1, ข้อ 2) แทนคำว่า "มาตรา" ตัวข้อความในไฟล์ถูกสกัดออกมาอย่างสมบูรณ์แล้ว ไม่ได้เกิดข้อผิดพลาดในการอ่าน Text แต่อย่างใด | ตรวจสอบเนื้อหาไฟล์ .txt จริงในโฟลเดอร์ data/documents เพื่อยืนยันว่าข้อความครบถ้วน จากนั้นปรับเงื่อนไขในตัว Chunker ให้ตรวจจับทั้งคำว่า "มาตรา" สำหรับพระราชบัญญัติ/พระราชกำหนด และคำว่า "ข้อ" สำหรับระเบียบ/ข้อบังคับ เพื่อให้การแบ่ง Chunk ครอบคลุมเอกสารทุกประเภทใน Corpus |